

POSCO K NEW DEAL

35 일차 학습 교재

2026 년 9 월 8 일

머신러닝 기초와 Z-score 이상탐지

정상의 기준을 정하고 평균에서 벗어난 값을 찾는 방법

학습 범위	이번 교재에서 다루는 내용
25-01	머신러닝 최소 개념 · 특징과 정답 분리
25-02	이상탐지와 통계 기초 · 실습 1~4
25-03	Z-score 의 의미와 한계 · 실습 1~4

핵심 질문

값이 크다는 이유만으로 이상이라고 할 수 있을까요? 이 교재는 평소의 중심과 흔들림을 먼저 정한 뒤, 새로운 값이 그 기준에서 얼마나 멀리 떨어졌는지 설명합니다.

학습의 도착점

정상 데이터 96 개로 기준을 만들고, 전체 104 개에 절댓값 Z-score 를 적용하여 임계값 3 을 넘는 이상 후보 8 개를 추출합니다. 결과는 고장 확정이 아니라 점검 대상의 선별로 해석합니다.

이용 안내

학습 순서와 목차

개념을 이해한 뒤 코드와 결과를 연결해 읽습니다

각 단계는 정의, 예시, 코드, 실행 결과, 해석의 순서로 이어집니다. 코드를 외우기 전에 “무엇을 기준으로 어떤 행을 골랐는가”를 말로 설명해 보세요. 수식의 기호는 바로 아래에 풀이했습니다.

구성	주요 내용	쪽
Chapter 0	앞 수업과의 연결 및 학습 지도	3
STEP 1	머신러닝의 문제 유형과 학습 방식	4-6
STEP 2	특징 x 와 정답 y 및 25-01 실습	7-9
STEP 3	이상탐지의 대상과 운영상 해석	10-11
STEP 4	평균과 표준편차 및 25-02 실습	12-17
STEP 5	Z-score의 의미와 임계값	18-20
STEP 6	25-03 실습 1~4 해설	21-24
부록 A-C	공식 요약 · 자주 하는 실수 · 실습 정리	25-27
마무리	전체 학습 내용 확인	28

코드 경로와 실행 기준

코드 예시는 01_Python_Data_Analysis 안의 Practice 또는 Ipythonb 폴더를 작업 위치로 가정하여 ../Data/ 경로를 사용합니다. 다른 위치에서 실행한다면 실제 Data 폴더에 맞춰 경로를 바꿉니다.

강사님 코드의 계산 흐름과 결과를 기준으로 정리했습니다. 그래프는 제공된 CSV로 다시 그렸으며, 개념용 그래프에는 설명용 예시라고 표시했습니다. 수치 계산에는 반올림 전 값을 사용하고 최종 출력만 반올림합니다.

읽는 법 파란색은 정상 또는 기준, 주황색은 이상 그룹이나 기준의 차이를 나타냅니다. 그래프마다 제목과 범례를 먼저 확인하세요.

CHAPTER 0

추세 관찰에서 이상 판정으로

이동평균과 상관관계 이후의 학습 위치

앞 수업에서는 시계열의 이동평균으로 추세를, 이동표준편차로 변동성을 살펴보았습니다. 상관관계와 히트맵으로 여러 센서가 함께 움직이는지도 확인했습니다. 이번 수업은 그 관찰을 “이 값은 평소에서 얼마나 벗어났는가”라는 수치 기준으로 연결합니다.

관찰과 판정은 서로 다른 질문입니다

앞에서 묻던 질문	이번에 묻는 질문
시간이 흐르면서 값이 오르는가	지금 값이 정상 기준에서 얼마나 떨어졌는가
최근 흔들림이 커졌는가	평소 표준편차의 몇 배만큼 벗어났는가
두 센서가 함께 움직이는가	어떤 데이터를 우선 점검 후보로 뽑을 것인가

이번 수업의 전체 흐름

순서	해야 할 판단
1 문제 정의	분류인지 회귀인지, 라벨이 있는지 먼저 확인합니다.
2 데이터 이해	각 열의 의미를 파악하고 특징과 정답을 분리합니다.
3 정상 기준	정상 상태를 대표하는 데이터로 평균과 표준편차를 구합니다.
4 거리 계산	전체 분석 대상에 동일한 기준을 적용하여 Z 값을 계산합니다.
5 후보 추출	Z 값의 절댓값이 임계값을 넘는 행을 남깁니다.

Z-score 는 시간 순서를 직접 모델링하지 않습니다. 시간에 따른 추세나 센서 조합의 변화는 앞에서 배운 시계열-상관관계 관찰과 함께 살펴야 합니다. 단순한 한 가지 수치가 설비 상태의 모든 정보를 대신하지는 못합니다.

확인 질문 평균에서 멀리 떨어진 값과 최근 꾸준히 상승하는 추세는 같은 종류의 이상일까요? 하나는 점의 이탈이고, 다른 하나는 여러 시점의 패턴입니다.

STEP 1

머신러닝이 규칙을 만드는 방법

모델과 학습을 먼저 구분합니다

인공지능은 가장 넓은 분야이며, 머신러닝은 그 안에서 데이터로 규칙을 배우는 접근입니다. 딥러닝은 여러 층의 신경망을 사용하는 머신러닝의 한 종류입니다. 단순히 학습을 여러 번 반복하거나 모델끼리 경쟁시킨다는 뜻은 아닙니다. 규칙 기반 프로그램에서는 사람이 조건을 직접 적고, 학습 기반 접근에서는 데이터에서 패턴과 매개변수를 찾습니다.

용어	의미	수업의 비유
모델	입력을 받아 결과를 내는 규칙 또는 함수	완성된 레시피
학습	데이터를 이용해 규칙을 조정하는 과정	레시피를 다듬는 과정
예측 또는 추론	정해진 모델을 새 입력에 적용하는 과정	레시피로 실제 요리하기

모델과 서비스는 같은 말이 아닙니다

AI 서비스는 사용자가 접하는 화면과 기능을 포함한 제품입니다. 모델은 그 안에서 입력을 처리하는 핵심 요소입니다. 에이전트는 모델에 도구 사용과 작업 절차를 결합해 여러 단계를 수행하는 시스템으로 이해할 수 있습니다. 서비스 이름을 아는 것과 모델이 어떻게 학습하는지 아는 것은 다른 수준의 이해입니다.

예지정비에서 데이터가 하는 일

정비 방식	시점	주요 고려점
사후정비	고장이 난 뒤	정지 손실과 연쇄 피해
예방정비	정해진 주기	아직 쓸 수 있는 부품도 교체할 수 있음
예지정비	상태 변화와 위험 징후를 보고	신뢰할 수 있는 상태 데이터와 해석 필요

예방정비도 이력과 수명 데이터를 활용할 수 있습니다. 예지정비의 특징은 현재의 상태 데이터를 읽어 점검·정비 시점을 조정한다는 데 있습니다. 센서 기록을 모으고 정상 패턴을 파악한 뒤 달라지는 징후를 찾아야 합니다.

STEP 1 이어서

문제 유형과 학습 방식

무엇을 예측하며 어떤 정답을 갖고 있는가

문제	결과의 형태	설비 예시
분류	미리 정한 범주	정상인가 이상인가
회귀	연속적인 수치	잔여 수명은 얼마나 되는가
군집	비슷한 대상의 묶음	비슷한 운전 패턴끼리 묶기

0 과 1 처럼 숫자로 적힌 라벨이라도 두 범주를 나타낸다면 분류입니다. 숫자라는 외형보다 그 값의 의미가 중요합니다. 반대로 잔여 수명처럼 양의 크기를 예측하는 문제는 회귀로 볼 수 있습니다.

지도학습과 비지도학습

지도학습은 입력과 정답이 짝지어진 데이터로 관계를 학습합니다. 정상·고장 표시가 있는 과거 진동 기록으로 상태를 예측하는 경우가 해당합니다. 비지도학습은 정답을 학습 목표로 주지 않고 분포나 유사성에서 구조를 찾습니다. 라벨 없는 신규 펌프의 소리에서 다른 패턴을 찾는 경우를 생각할 수 있습니다.

상황	적절한 출발점	판단 이유
모터 기록에 정상·고장 표시가 있음	지도학습	입력에 대응하는 목표가 있음
새 펌프 소리만 쌓여 있음	비지도 접근	라벨 없이 평소 패턴을 파악
표시 없는 센서를 비슷하게 묶음	군집 분석	유사성으로 그룹을 구성

이번 z-score 실습의 정확한 위치

Z-score 는 통계량으로 기준을 만드는 방법이며, 그 자체가 복잡한 분류 모델을 학습하는 것은 아닙니다. 이번 코드는 label 이 0 인 데이터를 골라 정상 기준을 정하므로, 정상 데이터 선택에 라벨 정보를 사용합니다. 그 뒤 점수를 계산하는 식에는 label 을 넣지 않습니다.

구분 교안에서는 비지도 이상탐지의 기본 원리로 소개합니다. 다만 이번 실습은 정상 라벨을 이용한 기준 학습이라는 점에서 완전히 라벨을 쓰지 않는 절차와는 구분해야 합니다.

STEP 1 정리

새 데이터에서도 통하는 모델

학습과 평가를 분리해야 하는 이유

머신러닝 프로젝트는 수집, 전처리, 학습, 평가, 활용으로 이어집니다. 입력이 누락되거나 라벨이 틀리면 복잡한 모델도 신뢰할 수 있는 규칙을 배우기 어렵습니다. 데이터를 제대로 이해하고 정리하는 과정이 학습보다 먼저입니다.

학습 데이터와 테스트 데이터

학습 데이터는 규칙을 만드는 데 쓰고, 테스트 데이터는 그 규칙을 평가하기 위해 남겨 둡니다. 이미 본 문제에서 좋은 점수를 받는 것과 처음 보는 문제에서도 잘하는 것은 다릅니다. 새로운 데이터에 잘 적용되는 능력을 일반화라고 합니다.

교안의 입문 예시는 학습 70~80%, 테스트 20~30% 정도의 분리를 소개합니다. 모든 데이터에 적용되는 고정 비율은 아닙니다. 특히 시간 순서가 있는 설비 데이터는 미래가 과거 학습에 섞이지 않도록 시간과 설비 단위를 고려해야 합니다.

학습 점수 / 테스트 점수	우선 해석	점검 방향
98 / 55	과적합 의심	학습 내용에만 맞춰졌는지 확인
62 / 60	과소적합 가능성	특징과 모델이 패턴을 담는지 확인
88 / 85	일반화가 비교적 양호	분리 방식과 평가 기준도 점검

위 점수는 교안의 설명용 예시입니다. 두 점수가 비슷하다는 이유만으로 좋은 모델이라고 할 수는 없습니다. 둘 다 낮다면 문제 자체의 어려움, 라벨 품질, 평가 기준도 확인해야 합니다. 점수만으로 원인을 확정하지는 않습니다.

과적합과 과소적합

과적합은 큰 흐름뿐 아니라 학습 데이터의 우연한 잡음까지 따라간 상태입니다. 과소적합은 필요한 패턴조차 충분히 담지 못한 상태입니다. 대표성 있는 데이터를 확보하고 모델 복잡도를 조절하며, 학습에 쓰지 않은 데이터로 확인하는 것이 기본입니다.

이번 실습 오늘은 별도 학습-테스트 분리나 모델 성능 평가를 구현하지 않습니다. 104 개에서 후보 8 개를 찾은 결과를 미래 설비의 성능 보장으로 해석하면 안 됩니다.

STEP 2

특징 x 와 정답 y

각 열의 역할을 먼저 결정합니다

특징은 판단에 사용하는 단서입니다. 온도, 진동, 소리의 크기와 같은 측정값이나 여기서 추출한 요약값이 특징이 될 수 있습니다. 정답은 모델이 맞히도록 정한 목표입니다. 같은 데이터라도 목표가 바뀌면 특징과 정답의 역할이 달라질 수 있습니다.

MIMII 열	뜻	이번 역할
rms	소리 신호의 크기를 요약한 제곱평균제곱근 특징	특징 x
spectral_centroid	스펙트럼이 어느 주파수 쪽에 치우쳤는지 나타내는 중심	특징 x
zero_crossing_rate	신호가 0 을 가로지르는 정도를 요약한 특징	특징 x
label	정상 0 과 이상 1 의 구분	정답 y

제공 CSV 는 이미 추출된 특징 표입니다. 원음 파형이나 특징 추출 설정을 다시 계산하는 실습은 아닙니다. 그래프는 파일의 원척도를 그대로 사용하며, 파일에 명시되지 않은 물리 단위를 새로 붙이지 않습니다.

정답을 특징에 넣으면 생기는 일

label 을 x 에 포함하면 모델이 센서 패턴을 이해하는 대신 정답을 그대로 읽을 수 있습니다. 이것이 데이터 누출의 대표적인 형태입니다. 목표값 자체뿐 아니라 미래에야 알 수 있는 정보, 목표를 직접 계산할 수 있는 열도 함께 살펴야 합니다.

자료	행과 열	분리 결과
오디오 특징	104 행 4 열	x 는 104×3, y 는 104 개
설비 센서 표본	40 행 5 열	x 는 40×2, y 는 40 개

확인 질문 label 이 숫자 열이라 자동으로 모든 숫자 열을 x 로 고르면 안전할까요? 안전하지 않습니다. 자료정보다 각 열의 의미를 먼저 확인해야 합니다.

STEP 2 실습

25-01 실습 1 오디오 특징 분리

정답 열을 제외한 세 특징만 선택합니다

분석의 시작은 파일을 읽는 일보다 각 열의 역할을 구분하는 일입니다. label 한 열은 y로 분리하고, rms와 나머지 두 특징은 열 이름 목록으로 선택합니다.

```
import pandas as pd

df = pd.read_csv('../Data/25_mimii_features.csv')
y = df['label']
X = df[['rms', 'spectral_centroid',
        'zero_crossing_rate']]

print(X.shape)
print(y.shape)
print('label' in X.columns)

> (104, 3)
> (104,)
> False
```

대괄호의 개수가 만드는 차이

df['label']은 한 열을 Series로 선택합니다. 그래서 y.shape는 (104,)처럼 한 차원의 길이만 나타납니다. df[...]은 열 이름 목록을 받아 DataFrame을 만듭니다. X.shape의 첫 값은 행 수, 두 번째 값은 특징 수입니다.

확인할 것	정상적인 결과	의미
X의 열 수	3	입력 단서는 세 특징
X와 y의 행 수	각각 104	같은 표본끼리 대응
X에 label 포함 여부	False	정답을 입력에서 제외

한 행의 대응을 유지해야 합니다

X와 y를 따로 섞거나 한쪽에서만 행을 지우면 특징과 정답의 짝이 어긋날 수 있습니다. 이번처럼 같은 df에서 분리하면 처음의 인덱스 대응이 유지됩니다. 이후 전처리에서도 동일한 표본을 함께 처리해야 합니다.

STEP 2 실습

25-01 실습 2 설비 센서 분리

고장 임박 여부를 목표로 정합니다

이번 목표는 failure_soon, 즉 고장이 임박했는지를 구분하는 것입니다. 입력은 cycle 과 sensor_2 로 제한합니다. cycle 은 관측 회차이며 날짜나 시각 자체가 아닙니다.

```
sm = pd.read_csv('../Data/25_cmapss_sample.csv')
y = sm['failure_soon']
X = sm[['cycle', 'sensor_2']]

print(X.shape)
print(y.value_counts().to_dict())
print(X.columns.tolist())

> (40, 2)
> {0: 32, 1: 8}
> ['cycle', 'sensor_2']
```

왜 RUL 을 제외할까요

RUL 은 남아 있는 유효 수명입니다. 고장 임박 여부는 잔여 수명과 직접 관련된 목표이므로, 이 문제에서 RUL 을 특징에 넣으면 목표 정보를 미리 알려 주는 단서가 될 수 있습니다. 실제 예측 시점에 이용할 수 있는 센서 정보와, 미래 고장 이후에야 계산할 수 있는 정보를 구분해야 합니다.

열 또는 정보	처리	이유
failure_soon	y 로 사용	이번에 맞히려는 목표
cycle, sensor_2	X 로 사용	실습에서 정한 입력 특징
RUL	X 에서 제외	미래 수명 정보가 목표를 드러낼 수 있음
unit_id	이번 X 에서 제외	설비 식별자이며 이번 입력은 두 특징으로 제한

정상 32 개와 임박 8 개는 이 40 행 표본의 정답 분포입니다. 모든 현장 데이터의 고장 비율이 같다는 뜻은 아닙니다. 또한 이 분포를 출력했다고 해서 모델을 평가한 것도 아닙니다.

복습 X 를 정의할 때 “숫자 열을 모두 넣는다”가 아니라 “현재 시점에서 쓸 수 있는 단서를 명시한다”는 관점으로 접근하세요.

STEP 3

이상탐지는 정상을 먼저 정의합니다

이상 후보와 고장 확정은 다릅니다

이상탐지는 평소의 정상 패턴에서 동떨어진 데이터를 찾는 작업입니다. 모든 고장 종류를 미리 정의하기는 어렵지만, 정상적으로 운전할 때의 모습을 기록해 두면 달라진 징후를 비교할 수 있습니다. 설비 고장은 드물고 형태도 다양하므로 정상 기준을 활용하는 접근이 유용합니다.

종류	관찰 대상	예시
점 이상	한 값의 큰 이탈	진동 값 하나가 평소 범위를 크게 초과
맥락 이상	상황과 값의 조합	정지 중인데 가동 중 수준의 신호가 유지
집단 이상	여러 값이 이루는 패턴	값은 범위 안이지만 계속 증가하는 추세

한 특징의 평균과 표준편차를 사용하는 Z-score 는 점 이상을 찾는 기본 도구입니다. 맥락이나 연속된 패턴을 식에 직접 넣지 않으므로, 값 하나하나는 평범한데 전체 패턴이 이상한 경우를 놓칠 수 있습니다.

결측치와 이상치

결측치는 값이 없는 상태입니다. 이상치는 값은 있지만 평소와 다른 상태입니다. 결측치를 0 으로 채우면 실제로 0 이 측정된 경우와 구분할 수 없게 됩니다. 원인과 측정 조건을 확인한 뒤 처리해야 합니다.

이상탐지에서 큰 값을 무조건 지우면 찾으려던 신호를 먼저 없애는 셈입니다. 정상 기준을 만드는 자료에서 오염을 점검하는 일과, 탐지 대상 전체에서 이상 후보를 삭제하는 일은 구분해야 합니다. 원본을 보존하고 후보를 따로 추출합니다.

현장 해석 큰 Z 값만으로 베어링 고장이나 센서 불량을 확정하지 않습니다. 운전 상태, 부하, 정비·알람 기록, 관련 센서와 함께 확인할 점검 신호입니다.

STEP 3 이어서

오탐과 미탐을 함께 살핍니다

경보가 어떤 행동으로 이어질지 생각합니다

실수	뜻	영향
오탐	정상을 이상이라고 경고	불필요한 점검과 경보 불신
미탐	실제 이상을 놓침	고장 징후를 방치할 가능성

임계값을 낮추면 후보를 더 많이 잡습니다. 실제 이상을 놓칠 가능성을 줄일 수 있지만 정상도 경고할 수 있습니다. 임계값을 높이면 후보가 줄어들고, 경미한 이상까지 제외할 수 있습니다. 같은 점수에 같은 데이터와 기준을 적용할 때 생기는 관계입니다.

어떤 실수의 비용이 더 큰가

미탐의 손실이 큰 설비는 작은 징후도 점검할 필요가 있습니다. 반대로 불필요한 점검 비용이 큰 상황에서는 과도한 경보를 줄여야 합니다. 이 판단은 통계량만으로 결정할 수 없으며 설비 중요도와 대응 절차를 함께 고려합니다.

접근법	기준	이번 학습과의 관계
통계 기반	평균·표준편차 또는 사분위수	Z-score 와 IQR 의 기본 원리
거리 기반	이웃 또는 중심에서의 거리	멀리 떨어진 점이라는 직관
모델 기반	학습된 분포나 패턴	복잡한 패턴을 다루는 확장 방향

복잡한 모델이 항상 더 좋은 것은 아닙니다. 단순한 기준은 빠르게 계산하고 설명하기 쉽습니다. 분포가 여러 운전 상태로 나뉘거나 여러 센서의 조합이 중요하다면, 상태를 구분하거나 적절한 다른 방법을 검토해야 합니다.

탐지 결과에 필요한 설명

“이상입니다”라는 말만으로는 점검할 수 없습니다. 어느 대상에서 어떤 값이 기준을 얼마나 벗어났는지 함께 제시해야 합니다. 이번 데이터는 표본 행 단위이므로 행 인덱스로 대상을 확인합니다. 인덱스를 실제 시각이나 설비 번호로 오해하지 않습니다.

STEP 4

평균과 표준편차로 정상을 요약합니다

중심과 흩어짐을 함께 봅니다

평균은 데이터가 모인 중심을 요약합니다. 모든 값을 더해 개수로 나누므로 극단적인 값의 영향을 받습니다. 이상탐지의 기준 평균은 정상 운전 상태를 대표하는 자료에서 구하는 것이 중요합니다.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

x_i 는 i 번째 측정값, n 은 유효한 정상 측정값 수, $\bar{x}$ 는 표본평균입니다.

평균에서 각 값을 뺀 편차에는 양수와 음수가 함께 존재합니다. 편차를 그대로 더하면 상쇄되므로, 제곱하여 흩어짐을 계산합니다. 표본분산에 제곱근을 취한 것이 표본표준편차입니다.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}, \quad s = \sqrt{s^2}$$

s^2 는 표본분산, s 는 표본표준편차입니다. 이 교재의 실습은 분모에 $n-1$ 을 사용합니다.

단위와 해석

분산의 단위는 원래 단위의 제곱이고, 표준편차는 원래 데이터와 단위가 같습니다. 표준편차가 작으면 평균 주변에 좁게 모여 있고, 크면 넓게 퍼져 있습니다. “평균적으로 떨어진 정도”라는 직관은 유용하지만 절댓값 거리의 단순 평균과 동일한 계산은 아닙니다.

통계량	알려 주는 것	그것만 볼 때의 한계
평균	중심이 어디인지	흔들리는 폭을 알 수 없음
표준편차	얼마나 흩어져 있는지	중심 위치를 알 수 없음

핵심 평균은 기준점이고 표준편차는 거리의 눈금입니다. 두 값이 있어야 같은 측정값도 설비의 평소 흔들림에 맞춰 해석할 수 있습니다.

STEP 4 이어서

평균이 같아도 데이터는 다릅니다

표준편차와 ddof 를 함께 이해합니다




그림 1 교안의 설명용 값으로 재구성한 평균과 산포 비교

A 설비의 값은 0.09, 0.10, 0.11, 0.10 으로 좁게 모입니다. B 설비는 0.02, 0.18, 0.05, 0.15 로 넓게 흩어집니다. 두 평균은 0.10 으로 같지만, 새로운 0.16 을 보았을 때 평소와 다른 정도는 같지 않습니다.

NumPy 와 pandas 의 기본값 차이

$$s_d = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n - d}}$$

d 는 ddof 이며 분모에서 차감하는 자유도 수입니다. d=0 이면 n, d=1 이면 n-1 로 나눕니다.

호출	기본 ddof	이번 기준과 맞추기
NumPy 배열.std()	0	배열.std(ddof=1)
pandas Series.std()	1	기본 호출이 표본 기준

ddof=1 은 표본분산의 편향을 보정하는 방식입니다. 제곱근까지 취한 표본표준편차가 정확한 불편추정량이라는 뜻은 아닙니다. 실습에서는 두 도구의 기준을 맞춰 같은 수치를 얻는 점을 우선 기억합니다.

STEP 4 이어서

정규분포와 세 배 표준편차

99.7%는 정규분포 가정에서 나오는 비율입니다




그림 2 이론적 정규분포의 면적 비율이며 실제 표본의 고장 확률이 아닙니다

정규분포는 평균을 중심으로 대칭인 종 모양 분포입니다. 이론적으로 평균에서 표준편차 1 배 이내에는 약 68.3%, 2 배 이내에는 약 95.4%, 3 배 이내에는 약 99.7%가 포함됩니다. 멀리 떨어진 값은 이 분포 아래에서 드문 값입니다.

$$L = \bar{x} - 3s, \quad U = \bar{x} + 3s$$

L 과 U 는 각각 아래·위 경계입니다. 실습에서는 정상 표본에서 추정한 평균과 표준편차를 사용합니다.

세 배 범위 밖의 값이 드물다는 것과 고장이라는 것은 다릅니다. 분포가 치우치거나 여러 운전 상태가 섞이면 99.7%라는 해석을 그대로 쓸 수 없습니다. 표본으로 추정한 구간의 포함 비율 역시 정확히 99.7%가 되지는 않습니다.

주의 3σ 는 고장 확률 99.7%나 탐지 정확도 99.7%를 뜻하지 않습니다. 임계값 3 은 분포와 현장 조건을 검토하면서 쓰는 출발 기준입니다.

STEP 4 실습

25-02 실습 1 과 2 정상 기준 계산

정상 96 개를 골라 평균과 표준편차를 구합니다

```
df = pd.read_csv('../Data/25_mimii_features.csv')
normal = df[df['label'] == 0]
mean_rms = normal['rms'].mean()
std_rms = normal['rms'].std()

low = mean_rms - 3 * std_rms
high = mean_rms + 3 * std_rms
print(len(normal))
print(round(mean_rms, 4), round(std_rms, 4))
print(round(low, 3), round(high, 3))

> 96
> 0.1015 0.0184
> 0.046 0.157
```

조건식이 행을 고르는 과정

`df['label'] == 0` 은 각 행이 정상인지 True 또는 False 로 표시합니다. 이 조건을 `df[...]`에 넣으면 True 인 행만 남습니다. 그 뒤 rms 열에 `mean()`과 `std()`를 적용하므로 두 통계량 모두 정상 96 개에서 계산됩니다.

$$L = 0.1014760 - 3 \times 0.0184076 \approx 0.046253, \quad U \approx 0.156699$$

계산은 전체 정밀도로 수행했습니다. 표시한 소수 자릿수만 줄였으며 경계는 약 0.046253 과 0.156699 입니다.

이 구간은 정상 기준에 따른 rms 의 참고 범위입니다. 전체 104 개의 평균과 표준편차를 사용한 구간이 아닙니다. 이후 새 값이나 전체 분석 대상에 이 같은 기준을 적용해야 비교가 일관됩니다.

출력과 계산 0.1015 와 0.0184 를 다시 입력하면 경계가 조금 달라집니다. `mean_rms` 와 `std_rms` 변수에는 반올림하지 않은 값을 유지하고 출력할 때만 `round` 를 사용하세요.

STEP 4 실습

25-02 실습 3 분포를 그림으로 읽기

히스토그램과 박스플롯은 서로 다른 정보를 보여 줍니다




그림 3 전체 분포와 정상 데이터 확대 비교입니다. 주황 점선은 정상 평균 $\pm 3s$ 경계입니다.

전체 rms 히스토그램에서는 낮은 값에 대부분의 표본이 모이고 큰 값 쪽에 드문 표본이 떨어져 있습니다. 정상 데이터만 확대하면 중심 주변의 흔들림이 더 잘 보입니다. 전체 분포가 치우쳤다고 해서 정상 그룹 자체도 같은 모양이라고 단정하면 안 됩니다.

```
import matplotlib.pyplot as plt

plt.hist(df['rms'], bins=20)
plt.xlabel('rms')
plt.ylabel('Count')
plt.show()

plt.boxplot(df['rms'])
plt.show()
```

bins 와 빈도

bins=20 은 값의 범위를 20 개 구간으로 나누겠다는 뜻입니다. 막대 높이는 해당 구간에 들어간 표본 수입니다. 막대가 높다고 측정값 자체가 큰 것은 아닙니다. 구간 수를 바꾸면 모양이 달라질 수 있으므로 중심과 꼬리의 큰 특징부터 읽습니다.

확인 그림의 가로축은 표본의 순서나 시간이 아니라 rms 값입니다. 오른쪽 꼬리를 시간이 지나며 값이 증가한 추세라고 해석하지 않습니다.

STEP 4 실습

25-02 실습 4 특징별 평균 비교

세 특징을 같은 단위인 것처럼 비교하지 않습니다




그림 4 정상·이상 그룹의 특징별 평균이며 각 패널의 세로축 척도는 다릅니다

```
abnormal = df[df['label'] == 1]
cols = ['rms', 'spectral_centroid',
        'zero_crossing_rate']
for col in cols:
    print(col, round(normal[col].mean(), 3),
          round(abnormal[col].mean(), 3))
```

```
> rms 0.101 0.501
> spectral_centroid 1784.023 2871.663
> zero_crossing_rate 0.081 0.222
```

제공 표본에서는 세 특징 모두 이상 그룹의 평균이 더 큼니다. rms 가 높다는 것은 소리 크기 특징의 증가이고, spectral_centroid 와 zero_crossing_rate 의 상승은 각각 해당 소리 특징의 변화를 나타냅니다. 단일 평균만으로 특정 부품 고장 원인을 확정하지는 않습니다.

감별력을 판단할 때의 주의점

spectral_centroid 는 수천 단위이고 rms 는 소수 단위입니다. 원척도의 평균 차이가 가장 크다는 이유만으로 가장 좋은 특징이라고 할 수 없습니다. 각 특징의 그룹 내 흠어짐과 두 그룹의 겹침도 확인해야 합니다. 이 실습의 결론은 "세 특징에서 그룹 평균의 차이를 관찰했다"입니다.

STEP 5

Z-score 는 표준편차 단위의 거리입니다

중심에서의 차이를 평소 흔들림으로 나눕니다

Z-score 는 한 값이 정상 평균에서 표준편차의 몇 배만큼 떨어졌는지 나타냅니다. 같은 10 의 차이라도 평소 흔들림이 1 인 센서와 20 인 센서에서는 의미가 다릅니다. 표준편차로 나누면 이런 차이를 고려할 수 있습니다.

$$z = \frac{x - \bar{x}_{\text{normal}}}{s_{\text{normal}}}$$

x 는 평가할 값, $\bar{x}_{\text{normal}}$ 과 s_{normal} 은 정상 기준 데이터의 평균과 표본표준편차입니다. Z 값에는 원래 물리 단위가 남지 않습니다.

분자는 차이이고 분모는 눈금입니다

먼저 현재 값에서 정상 평균을 빼면 중심과의 차이가 나옵니다. 이 차이를 표준편차로 나누면 평소 변동의 몇 배인지 알 수 있습니다. 분모가 작을수록 같은 차이도 큰 Z 값이 됩니다. 이것이 절댓값의 크기만 보는 것과 다른 점입니다.

$$z = \frac{68 - 50}{5} = 3.6$$

교안의 설명용 예시입니다. 평균 50, 표준편차 5 가 주어진 경우 값 68 의 Z 값은 3.6 입니다.

다음 실습에서 다섯 정상 값으로 계산하는 표준편차는 약 1.5811 입니다. 같은 값 68 이라도 그 기준에서 계산하면 약 11.4 가 됩니다. 3.6 과 11.4 는 서로 모순이 아니라 기준 표준편차가 다른 결과입니다.

부호 있는 Z	의미
양수	정상 평균보다 큰 쪽
0	정상 평균과 같은 값
음수	정상 평균보다 작은 쪽

핵심 큰 양수만 이상 후보인 것은 아닙니다. 작은 방향으로 크게 떨어진 값도 확인해야 하므로 양방향 판정에는 절댓값을 사용합니다.

STEP 5 이어서

부호와 절댓값을 구분합니다

표준화와 이상 판정의 차이를 이해합니다




그림 5 실습 1의 정상 다섯 값으로 계산한 부호 있는 Z 값

값 40은 평균 50보다 작아서 음수이고, 값 68은 평균보다 커서 양수입니다. 어느 쪽으로 움직였는지는 부호로 확인합니다. 기준에서 얼마나 멀리 떨어졌는지는 절댓값으로 확인합니다. 값 53은 같은 기준에서 약 1.90이므로 3배 안쪽입니다.

$$a = |z|, \quad a > \tau \implies \text{anomaly candidate}$$

a 는 부호를 제거한 거리, τ 는 임계값입니다. 이번 실습의 τ 는 3이며 엄격한 초과 조건을 사용합니다.

표준화한다고 모두 0부터 1이 되지는 않습니다

Z-score 표준화는 기준 평균을 빼고 기준 표준편차로 나누는 변환입니다. 값이 0~1에만 갇히는 최소·최대 정규화와 다릅니다. 음수도 나오고 1보다 큰 값도 나옵니다. 동일한 기준 표본을 같은 표준편차 정의로 변환하면 부호 있는 Z의 평균은 0, 표준편차는 1이 됩니다.

정상 기준을 전체 데이터에 적용한 Z 값의 평균과 표준편차까지 반드시 0과 1이 되는 것은 아닙니다. 특히 `np.abs`를 적용한 `z_rms`는 모두 0 이상이며, 부호 있는 표준화 값과 같은 분포를 갖지 않습니다.

코드 연결 실습 열 이름은 `z_rms`이지만 저장 내용은 절댓값 Z입니다. 열 이름만 보고 음수 방향의 정보가 남아 있다고 생각하지 마세요.

STEP 5 정리

정상 기준의 오염과 z-score 의 한계

기준을 만드는 자료와 탐지 대상을 분리합니다




그림 6 제공 CSV 로 비교한 평균과 3 배 표준편차 구간

이상 표본까지 포함하면 평균이 큰 값 쪽으로 이동하고 표준편차도 커집니다. 같은 관측값을 더 넓은 자료 재계 되므로 이탈이 덜 심해 보일 수 있습니다. 정상 96 개를 고르는 첫 단계가 점수 계산 자체만큼 중요합니다.

한계	왜 생기는가	해석 시 보완
분포에 민감	평균과 표준편차가 분포를 요약	히스토그램으로 모양 확인
극단값에 민감	기준 평균과 산포가 변함	정상 기준 자료의 오염 점검
조합·추세를 놓침	한 특징의 한 값을 계산	운전 조건과 시계열도 확인
표준편차 0	거리의 눈금이 없음	계산 중단 후 기준 자료 점검

정상이 확인된 초기 운전 기간이나 정비 후 안정 구간을 기준으로 삼을 수 있습니다. 다만 초기 데이터라고 무조건 정상은 아니며, 기동·부하 변화가 섞이지 않았는지 확인해야 합니다. 라벨이 없을 때도 극단값을 임의로 지우기보다 정상 구간을 확인한 근거가 필요합니다.

이해 이상 후보를 추출한 뒤에도 원본을 남겨 두어야 합니다. "기준에서 제외"와 "증거를 삭제"는 같은 행동이 아닙니다.

STEP 6 실습

25-03 실습 1 손으로 z 값 계산

정상 다섯 값과 새 값 세 개를 구분합니다

정상 기준으로 48, 50, 52, 49, 51 을 사용합니다. 이 값들로 평균과 표본표준편차를 계산한 뒤, 새로 제시한 53, 68, 40 을 평가합니다. 새 값 세 개를 기준 계산에 섞지 않습니다.

$$\bar{x} = 50, \quad s = \sqrt{\frac{4+0+4+1+1}{5-1}} = \sqrt{2.5} \approx 1.5811$$

다섯 정상 값의 편차 제곱 합은 10 이며, 표본분산은 $10 \div 4 = 2.5$ 입니다.

```
import numpy as np

vals = np.array([48, 50, 52, 49, 51])
m = vals.mean()
s = vals.std(ddof=1)
print(m, round(s, 4))
for v in [53, 68, 40]:
    z = (v - m) / s
    print(v, round(z, 1))

> 50.0 1.5811
> 53 1.9
> 68 11.4
> 40 -6.3
```

새 값	부호 있는 Z	절댓값과 3 비교	해석
53	약 1.9	3 이하	이 기준에서 후보 아님
68	약 11.4	3 초과	큰 방향의 이상 후보
40	약 -6.3	3 초과	작은 방향의 이상 후보

ddof=1 을 생략하면 NumPy 의 기본값은 0 이므로 표준편차와 Z 값이 바뀝니다. 강사님 코드와 동일하게 표본 기준을 사용합니다. 수식에 쓰는 m 과 s 를 출력용 반올림 값으로 덮어쓰지 않습니다.

STEP 6 실습

25-03 실습 2 데이터와 기준 준비

분석 대상은 104 개이고 기준 자료는 96 개입니다

```
df = pd.read_csv('../Data/25_mimii_features.csv')
print(df.shape)
print(df['label'].value_counts().to_dict())

normal = df[df['label'] == 0]
mean_rms = normal['rms'].mean()
std_rms = normal['rms'].std()
print(round(mean_rms, 4), round(std_rms, 4))

> (104, 4)
> {0: 96, 1: 8}
> 0.1015 0.0184
```

변수 세 개의 역할

변수	포함하는 것	사용하는 단계
df	정상과 이상을 포함한 전체 104 개	점수를 계산하고 후보를 추출
normal	label 이 0 인 정상 96 개	기준 통계량을 계산
mean_rms, std_rms	정상 rms 의 중심과 산포	전체 행에 공통 적용

제공된 오디오 CSV 에는 결측치가 없고 네 열 모두 수치로 읽힙니다. 그렇더라도 다른 파일에 적용할 때는 열 이름, 행 수, 결측치와 무한대, 표준편차가 유효한지를 확인해야 합니다. 파일이 정상적으로 열렸다는 사실만으로 계산 기준이 안전한 것은 아닙니다.

순서대로 실행해야 하는 이유

이전 노트북에서 사용한 변수는 다른 노트북에 자동으로 생기지 않습니다. pandas 를 pd 로 가져오고 파일을 읽은 뒤 normal, mean_rms, std_rms 를 정의해야 합니다. 중간 셀만 실행해서 예전 변수값이 남아 있으면 다른 데이터의 기준이 적용될 수 있습니다.

핵심 표본 수 96 과 104 가 다르게 나오는 것은 정상입니다. 첫 번째는 기준을 만드는 행 수이고, 두 번째는 평가할 전체 행 수입니다.

STEP 6 실습

25-03 실습 3 절댓값 z 열 만들기

하나의 정상 기준을 전체 행에 적용합니다

```
df['z_rms'] = np.abs(
    (df['rms'] - mean_rms) / std_rms
)

print(df['z_rms'].round(1).nlargest(3).tolist())

> [28.1, 23.3, 22.5]
```

한 줄을 세 단계로 읽기

계산	무엇을 하는가
df['rms'] - mean_rms	각 행에서 같은 정상 평균을 뺍니다.
... / std_rms	각 차이를 같은 정상 표준편차로 나눕니다.
np.abs(...)	방향을 제거하여 양방향 거리를 만듭니다.

pandas Series 전체에 스칼라 평균과 표준편차를 적용하므로 반복문 없이 모든 행을 계산합니다. 결과 Series를 새 열 z_rms에 넣으면 원래 행과 같은 인덱스에 맞춰 점수가 저장됩니다. 원본 CSV 파일은 이 코드만으로 변경되지 않습니다.

가장 큰 점수 세 개를 확인하는 이유

nlargest(3)은 큰 값 세 개를 골라 내림차순으로 반환합니다. tolist()는 결과를 일반 파이썬 리스트로 바꿉니다. 강사님 코드는 소수 첫째 자리로 반올림한 뒤 큰 값을 골랐습니다. 세 값은 정상 평균에서 약 28.1 배, 23.3 배, 22.5 배 표준편차만큼 떨어져 있다는 뜻입니다.

반올림 정확한 순위가 필요한 상황에서는 원래 값으로 nlargest(3)을 먼저 적용한 뒤 반올림하는 편이 안전합니다. 이번 자료에서는 표시되는 상위 세 값이 같습니다.

상위 점수만 확인하는 것과 임계값을 넘는 모든 후보를 추출하는 것은 다릅니다. 다음 실습에서는 “세 개만”이라는 개수 조건 대신 “3 보다 큼”이라는 기준 조건을 사용합니다.

STEP 6 실습

25-03 실습 4 임계값으로 후보 추출

절댓값 Z가 3을 넘는 모든 행을 남깁니다

```
threshold = 3.0
anomalies = df[df['z_rms'] > threshold]
print(len(anomalies))
anomalies.head()
```

> 8

`df['z_rms'] > threshold`는 104개 행 각각의 판정 조건입니다. `df[...]`는 True인 행만 남깁니다.

`len(anomalies)`는 전체 후보 수이고, `head()`는 그중 앞의 다섯 행만 미리 보여 줍니다. 화면에 다섯 행이 나왔다고 후보가 다섯 개라는 뜻은 아닙니다.

원래 인덱스	rms	z_rms
0	0.6196	28.1473
10	0.3925	15.8100
16	0.4950	21.3783
19	0.5158	22.5083
37	0.5098	22.1824
56	0.4470	18.7707
68	0.5301	23.2852
78	0.4984	21.5630

위 표는 추출된 8개 전체를 원래 행 순서로 정리한 것입니다. rms와 절댓값 Z만 표시했으며, 인덱스는 CSV를 읽었을 때의 행 식별자입니다. 인덱스의 간격을 시간 간격으로 해석하지 않습니다.

$$|z| > 3 \iff x < \bar{x} - 3s \text{ or } x > \bar{x} + 3s$$

표준편차가 양수일 때 두 조건은 같습니다. 정확히 경계와 같은 값은 > 조건으로 추출되지 않습니다.

결론 이번 자료에서는 후보 8개가 추출됩니다. 아직 후보를 찾는 단계이므로 이 숫자만으로 모델의 미래 성능이나 실제 고장 여부를 확정하지 않습니다.

APPENDIX A

핵심 개념과 공식 한 장 정리

중심을 정하고 거리를 계산한 뒤 기준과 비교합니다

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

평균은 정상 데이터의 중심입니다. n 은 유효한 정상 값의 개수입니다.

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}, \quad s = \sqrt{s^2}$$

표본표준편차는 평소의 흔들림을 재는 눈금입니다. n 은 2 이상이어야 합니다.

$$z = \frac{x - \bar{x}_{\text{normal}}}{s_{\text{normal}}}$$

부호는 평균의 위·아래 방향이고 절댓값은 떨어진 정도입니다. 기준 표준편차는 양수여야 합니다.

$$L = \bar{x} - 3s, \quad U = \bar{x} + 3s$$

정상 평균에서 표본표준편차의 세 배만큼 양쪽으로 펼친 참고 구간입니다.

기억할 값	이번 수업의 결과
MIMII 분리	X (104, 3) / y (104,)
정상 기준	96 개 / 평균 약 0.1015 / 표준편차 약 0.0184
3 배 구간	약 0.046~0.157
절댓값 Z 상위 3 개	28.1 / 23.3 / 22.5
실습 4 후보 수	임계값 3 초과 8 개

APPENDIX B

자주 하는 계산과 해석 실수

결과가 나오는 것과 해석이 맞는 것은 다릅니다

잘못 생각하기 쉬운 부분	바르게 이해하기
표준화하면 0~1 이 된다	Z 표준화는 음수와 1 보다 큰 값도 나옵니다.
z_rms 에는 방향이 남는다	실습에서는 np.abs 를 적용해 방향이 제거됩니다.
전체 평균으로 기준을 만들면 된다	이번 기준은 정상 96 개에서 구합니다.
정상 라벨은 전혀 쓰지 않았다	label=0 을 선택하는 데 라벨을 사용했습니다.
3σ 밖이면 고장 확정이다	통계 기준의 이탈이며 점검 후보입니다.
99.7%는 모델 정확도다	정규분포의 이론적 구간 포함 비율입니다.
ddof=1 은 표준편차의 편향을 완전히 없앤다	정확한 불편성 설명은 표본분산에 해당합니다.
모든 std() 기본값은 같다	NumPy 는 0, pandas Series 는 1 입니다.
np.abs 를 쓰면 원인까지 알 수 있다	방향도 사라지므로 원인 분석에는 원래 값이 필요합니다.
큰 평균 차이가 가장 좋은 특징이다	특징마다 단위·척도와 그룹 내 분산이 다릅니다.
head()의 행 수가 전체 후보 수다	앞의 일부만 표시합니다. 전체는 len 으로 셉니다.
표준편차 0 도 나누면 된다	0 으로 나눌 수 없으므로 기준을 점검해야 합니다.
NaN 을 0 으로 바꾸면 항상 해결된다	미측정과 실제 0 이 섞여 탐지 기준을 왜곡할 수 있습니다.
큰 이상값은 먼저 모두 지운다	원본과 탐지 대상을 보존하고 기준 오염만 따로 점검합니다.

Z-score 는 제트스코어라고 읽습니다. 분산은 편차 제곱의 요약이고 표준편차는 그 제곱근입니다. 분산에 제곱근을 취하는 것은 값을 반으로 줄인다는 뜻이 아닙니다.

APPENDIX C

박스플롯과 실습 복습

IQR 비교는 개념 수준에서 연결합니다




그림 7 전체 rms의 박스플롯이며 점은 기본 1.5 IQR 규칙의 바깥값입니다

$$IQR = Q_3 - Q_1, \quad [Q_1 - 1.5IQR, Q_3 + 1.5IQR]$$

Q_1 과 Q_3 는 제 1-제 3 사분위수입니다. 상자는 두 사분위수 사이를 나타내며 가운데 선은 중앙값입니다.

박스플롯의 수업은 경계 안에 있는 실제 관측값까지 이어집니다. 상자 밖에 있다고 모두 이상점인 것은 아니며, 수업 밖에 개별 점으로 표시된 값이 이 규칙의 후보입니다. IQR은 사분위수에 기반해 극단값에 비교적 덜 민감하지만 고장을 보증하거나 모든 분포에서 정확한 것은 아닙니다.

실습의 연결

25-01은 X 와 y 를 나누고, 25-02는 정상 기준과 분포를 살펴봅니다. 25-03은 정상 기준을 사용해 Z 의 절댓값을 계산하고 후보 행을 추출합니다. 오늘 범위는 25-03 실습 4까지이며, 후보를 시각화하고 후속 검증으로 이어가는 내용은 다음 학습의 출발점입니다.

참고 자료

2026년 9월 8일 수업 녹취와 25-01 교안 4~55쪽, 25-02 교안 4~50쪽, 25-03의 개념 설명 및 실습 1~4를 바탕으로 정리했습니다. 수치와 그래프는 25_mimii_features.csv 및 25_cmapss_sample.csv로 확인했습니다.

실행 흐름은 Jupyter Notebook의 25_01_leader_code.ipynb, 25_02_leader_code.ipynb, 25_03-p1-4_leader_code.ipynb에 대응합니다. 교안의 경로와 출력 표시는 이 저장소 구조와 읽기 편한 자릿수에 맞추었습니다.

마무리

정상 기준에서 이상 후보까지

계산을 끝낸 뒤에는 기준과 의미를 설명합니다

이번 수업의 중심은 복잡한 알고리즘이 아니라 비교의 기준을 정확히 세우는 일입니다. 데이터가 주어졌을 때 어떤 열이 단서이고 어떤 열이 정답인지 구분해야 합니다. 다음으로 정상 상태를 대표하는 자료를 골라 평균과 표준편차를 계산합니다.

새로운 값을 정상 평균에서 빼고 정상 표준편차로 나누면 평소 흔들림에 비해 얼마나 멀리 떨어졌는지 알 수 있습니다. 부호는 방향을, 절댓값은 이탈의 크기를 알려 줍니다. 절댓값이 임계값보다 큰 행을 추출하면 점검할 후보가 남습니다.

복습 질문	짧은 답
왜 정답 y 를 x 에서 빼나요	정답이 입력에 섞이는 데이터 누출을 막기 위해서입니다.
왜 정상 데이터만으로 평균을 구하나요	이상값이 기준 중심과 산포를 바꾸는 것을 막기 위해서입니다.
표준편차가 작은 센서는 어떤가요	같은 원칙도 차이라도 더 큰 Z 값이 나옵니다.
Z 가 음수이면 정상인가요	아닙니다. 평균보다 작은 방향이라는 뜻입니다.
threshold 를 높이면 무엇이 달라지나요	같은 점수에서 추출되는 후보가 줄어듭니다.
8 개를 추출했다는 결론의 범위는 어디까지인가요	이 표본과 기준에서 후보를 찾았다는 범위까지입니다.

실습 4 의 결과를 문장으로 설명하기

정상 라벨을 가진 96 개의 rms 값으로 평균 약 0.1015 와 표본표준편차 약 0.0184 를 구했습니다. 이 기준을 전체 104 개에 적용해 절댓값 Z -score 를 계산했고, 3 을 초과한 8 개를 이상 후보로 추출했습니다. 이 값들은 정상 기준에서 큰 이탈을 보이므로 우선 확인할 대상입니다.

마지막 확인 어떤 데이터를 기준으로 삼았는지, 어떤 조건으로 후보를 골랐는지, 그 결과가 무엇을 의미하지는 않는지까지 설명할 수 있으면 오늘의 핵심을 이해한 것입니다.